

Garay Acosta, Jessica Sofia

Quijano Garcia, Estefania

Rodriguez Torres, Juan Sebastian

Sales Galviz, Luis Felipe

Informe Proyecto Aprendizaje de Máquina

Parte Dos

Datos Externos Utilizados

En esta entrega no se incorporaron conjuntos de datos externos al entrenamiento. Sin embargo, el enunciado permite su uso con licencia verificable, por lo que se documentan a continuación las fuentes evaluadas para futuras iteraciones del proyecto.

Fuente	Enlace	Licencia	Uso en el proyecto
Proyecto Gutenberg (español)	gutenberg.org/browse/languages/es	Dominio público en EE.UU.	Documentado como fuente potencial para futuras iteraciones con textos del s. XVI–XIX.
Biblioteca Virtual Miguel de Cervantes	cervantesvirtual.com	CC BY-SA (gran parte del fondo)	Documentado como fuente de textos históricos en español (s. XV–XX).
Wikisource en español	es.wikisource.org	CC BY-SA 3.0	Documentado como alternativa de textos s. XIV–XX.

El único conjunto de datos empleado en el entrenamiento y la evaluación es el provisto por el curso (train.csv y eval.csv). No se extrajo, descargó ni procesó ningún recurso externo durante el desarrollo de esta entrega.

Posibles mejoras

Tras desarrollar el notebook y analizar los resultados obtenidos, se identificaron varios puntos de mejora que podrían contribuir a optimizar el desempeño y la capacidad de generalización del modelo:

- Reentrenamiento sobre el conjunto de datos completo antes de la inferencia final

Una vez identificada la configuración óptima del modelo mediante el proceso de validación interna, se recomienda reentrenar el modelo utilizando la totalidad de los datos de train.csv, eliminando la partición reservada para validación.

- Combinación de modelos mediante ensemble

Una de las estrategias más efectivas para mejorar la precisión consiste en combinar las predicciones de múltiples modelos entrenados de forma independiente. En lugar de depender de un único modelo, se pueden promediar las probabilidades producidas por distintas arquitecturas.

- Búsqueda sistemática de hiperparámetros

Si bien el notebook define hiperparámetros razonados manualmente, una exploración más sistemática mediante técnicas como búsqueda aleatoria o frameworks de optimización bayesiana, como Optuna, permitiría identificar configuraciones superiores de forma más eficiente.

- Análisis profundo de errores por década

Más allá de las métricas agregadas, un análisis detallado de los errores cometidos por el modelo por clase permite identificar patrones sistemáticos que orientan mejoras concretas. Por ejemplo, determinar qué décadas se confunden con mayor frecuencia entre sí, si los errores se concentran en textos cortos o mal preservados por el OCR, y cuáles son las características léxicas más discriminativas por época. Este diagnóstico puede guiar decisiones más informadas sobre preprocesamiento, aumentación de datos y arquitectura del modelo.

Uso de la IA

Durante el desarrollo de este proyecto se utilizaron herramientas de inteligencia artificial como apoyo en tareas de programación, revisión de código, redacción y búsqueda de información y recursos técnicos. Sin embargo, todo el contenido generado por estas herramientas fue revisado, validado y ajustado por el equipo antes de ser incorporado al trabajo final.

Las decisiones fundamentales del proyecto, incluyendo el diseño del modelo, la selección de hiperparámetros, la implementación de estrategias de entrenamiento y el análisis e interpretación de resultados fueron tomadas directamente por los integrantes del equipo, con base en criterios técnicos y en el proceso de experimentación realizado durante el desarrollo del notebook.